



POLITECHNIKA
LUBELSKA



POLITECHNIKA
LUBELSKA
WYDZIAŁ MATEMATYKI
I INFORMATYKI TECHNICZNEJ

RAPORT

z projektu zespołowego
z przedmiotu “Projekt z zakresu analizy
danych”

Szymon Chruśliński
Szymon Sergiel
Andrii Zapukhlyi

Politechnika Lubelska, Polska
Lublin 2025

Niniejszy fragment raportu stanowi samodzielnie wykonaną część projektu zespołowego, dotyczącą trzeciego z trzech niezależnych zadań.

I. Wstęp


Celem projektu jest zbudowanie i porównanie modeli opartych o narzędzia uczenia maszynowego, ze szczególnym uwzględnieniem modelowania liniowego. W ramach zadania zostaną opracowane **trzy różne modele wykorzystujące techniki uczenia maszynowego**, których efektywność zostanie dokładnie przeanalizowana.

Dodatkowo, stworzony zostanie **własny model liniowy**, który następnie zostanie porównany z wcześniej opracowanymi modelami, zarówno pod względem dokładności, jak i interpretowalności.

Raport obejmuje szczegółowy opis wykonanych czynności, wraz z algorytmami postępowania, wnioskami, oraz zrzutami ekranu. Dodatkowo załączone zostaną pliki z oryginalnymi obliczeniami.

II. Własny model liniowy i modele oparte o narzędzia uczenia maszynowego

Plik Excel (Prognozowanie 2.xlsx), z którego skorzystamy, zawiera dane w jednym arkuszu, w którym znajdują się 4 kolumny opisujące zmienne (t, data, liczba konkurencji, obrót). Zmienna t to liczba porządkowa obserwacji, ponumerowana od 1 do 9132, posiadająca liczbowy typ danych. Zmienna data jest zapisana w formacie dd.mm.rrrr i oznacza datę, w której wykonano obserwację. Kolejna zmienna, liczba konkurencji, również jest liczbową i przedstawia liczbę konkurencyjnych firm działających na rynku w danym momencie. Ostatnia zmienna, obrót, to liczba wskazująca wartość dziennego obrotu. Dane zostały wczytane do programu KNIME za pomocą node'a **Excel Reader**.



Rysunek 1: Wczytanie danych

Aby zwiększyć przejrzystość i ułatwić interpretację zmiennej data, została ona rozbita na kilka nowych zmiennych:

- **Year** – rok,
- **Month (Number)** – numer miesiąca,
- **Month (Name)** – nazwa miesiąca,
- **Day of Week (Number)** – numer dnia tygodnia,
- **Day of Week (Name)** – nazwa dnia tygodnia.

Do wyodrębnienia tych zmiennych wykorzystamy node **Date & Time Part Extractor**.

Date&Time column

data

Date and time fields

Field	Column name	
Year	Year	↑ ↓ 🗑️
Month (Number)	Month (Number)	↑ ↓ 🗑️
Month (Name)	Month (Name)	↑ ↓ 🗑️
Day of Week (Number)	Day of Week (Number)	↑ ↓ 🗑️
Day of Week (Name)	Day of Week (Name)	↑ ↓ 🗑️

+ Add field

Rysunek 2:Date & Time Part Extractor

Za pomocą node'a **Row Filter** dokonamy podziału danych na dwa zbiory: zbiór testowy i zbiór uczący. W celu utworzenia zbioru testowego zastosujemy filtr z warunkiem **Year equals 2024**, co pozwoli wyodrębnić wszystkie obserwacje z roku 2024. Natomiast dla zbioru uczącego użyjemy przeciwnego warunku, czyli **Year does not equal 2024**, aby wybrać dane z pozostałych lat.

Zbiór uczący posłuży do budowy i trenowania modelu, natomiast zbiór testowy pozwoli na ocenę skuteczności predykcji. Taki podział zapewnia, że model zostanie sprawdzony na nowych, niewidzianych wcześniej danych, co zwiększy jego wiarygodność.

Filter

Criterion 1

Filter column	Operator
Year	Equals

Value


2024

+ Add criterion

Rysunek 3:Tworzenie zbioru testowego

Po przeprowadzeniu podziału danych na zbiór uczący i testowy, liczebność obu zbiorów przedstawia się następująco: zbiór testowy zawiera 366 obserwacji, natomiast zbiór uczący składa się z 8766 obserwacji.

Teraz przyjrzymy się naszym danym, rysując wykres wartości obrotów w zależności od daty za pomocą wykresu liniowego, użyłem node'a **Line Plot**.




Rysunek 4: Wykres obrotów w zależności od daty

Na wykresie można zauważyć, że na obrót wpływają różne czynniki, takie jak skoki zależne od dnia tygodnia, sezonowość, a także liczba konkurencji. Wszystkie te elementy mają znaczący wpływ na zmienność obrotów w czasie.

Aby stworzyć model predykcji obrotów wyliczymy wartości bonusów dla skoków w poszczególnych dniach tygodnia, bonusów dla sezonowości, a także tych dotyczących liczby konkurencji. Zaczniemy od wyliczenia przyrostów dobowych.


Za pomocą node'a **Lag Column** tworzymy kolumnę zawierającą wartość obrotu przesuniętą o jeden dzień (obrot(-1)). Dzięki temu możliwe jest obliczenie przyrostu dobowego, co pozwoli na późniejsze wyznaczenie wartości skoków w danych.

Przyrost dobowy wyliczymy za pomocą następującej formuły w **Math Formula**:



Rysunek 5: Przyrost dobowy.


Spójrzmy na wykres, aby łatwiej znaleźć dni, w których występują znaczące skoki:



Rysunek 6: Skoki wartości obrotu w zależności od dnia

Z wykresu zauważamy, że skoki obrotów występują w dniach **4 (czwartek)** oraz **7 (niedziela)**. Wskazuje to na regularne zmiany w tych dniach tygodnia. Wyliczymy średnie wartości przyrostu dobowego w tych dniach oraz dniach je poprzedzających, żeby potwierdzić nasze przypuszczenia.

Zrobimy to za pomocą kilku node'ów:



Rysunek 7: Wyliczenie średnich przyrostów dobowych

Najpierw za pomocą **Row Filter** stosujemy filtr z warunkiem **Day of Week (Number) equals numer dnia**, następnie w **Column Filter** wybieramy przyrost dobowy. Na koniec dodajemy node **Statistics**, który wyliczy nam statystyki podstawowe dla przyrostu dobowego w każdym dniu. Nas interesuje przede wszystkim wartość średnia (**Mean**).

Dla poszczególnych dni tygodnia wyniki przedstawiają się następująco:


- **Środa:** 14,752
- **Czwartek:** 516,309
- **Sobota:** 13,892
- **Niedziela:** 610,352

Column	Min	Mean	Median	Max	Std. Dev.	Skewness	Kurtosis
przyrost dobowy	-229	516,3091	?	1 127	80,0817	-0,078	23,9487

Rysunek 8: Wynik node'a Statistics dla czwartku


Zgodnie z wcześniejszymi przypuszczeniami opartymi na analizie wykresu, wyniki statystyk potwierdzają, że faktycznie w dniach 4 (czwartek) i 7 (niedziela) występują duże skoki w wartości obrotu.

Stworzymy formułę rozdzielającą bonusy na poszczególne dni, co pozwoli nam wygładzić dane.




Rysunek 9: Formuła dotycząca bonusu dziennego.

Dzięki opracowanej formule rozdzielającej bonusy na poszczególne dni, możemy teraz wygładzić nasze dane za pomocą kolejnej formuły.



Rysunek 10: Formuła - wygładzenie tygodniowe

Spójrzmy jak wygląda nasze wygładzenie:




Rysunek 11: Wygładzenie tygodniowe - wykres

Udało nam się wygładzić obroty w obrębie pojedynczych dni tygodnia, co widać na przedstawionym wykresie. Niemniej jednak nadal zauważalne są skoki wynikające z sezonowości. Miesiące 1 i 2 cechują się wyraźnym spadkiem obrotów, natomiast w miesiącach 6, 7, 8 występują znaczne wzrosty. W związku z tym dalsze działania powinny skupić się na opracowaniu metod wygładzających te sezonowe wahania, aby uzyskać bardziej jednolite dane w skali całego roku.

Ponownie wyliczymy średnie wartości przyrostu dla miesięcy, które podejrzewamy o skoki oraz miesiącach je poprzedzających, żeby potwierdzić nasze przypuszczenia.

Zrobimy to za pomocą następujących node'ów:



Rysunek 12: Wyliczenie średnich wartości przyrostów dla miesięcy

Najpierw za pomocą **Row Filter** stosujemy filtr z warunkiem **Year equals rok (u nas 2000)**, następnie za pomocą kolejnych **Row Filter** wybierzemy konkretne miesiące. W **Column Filter** wybieramy wygładzenie tygodniowe. Na koniec dodajemy node **Statistics**, który wyliczy nam statystyki podstawowe w każdym miesiącu. Tak jak poprzednio interesuje nas przede wszystkim wartość średnia (**Mean**).

Dla poszczególnych miesięcy wyniki przedstawiają się następująco:

- **Luty:** 1937,414
- **Marzec:** 2889,71
- **Maj:** 3812,065
- **Czerwiec:** 4768,733

Column	Min	Mean	Median	Max	Std. Dev.	Skewness	Kurtosis
wygładzenie tygodniowe	4 493	4 768,7333	?	5 023	154,4387	-0,1262	-0,9854

Rysunek 13: Wynik node'a Statistics dla czerwca

Wyniki statystyk potwierdzają, że faktycznie w miesiącach 1, 2 oraz 6, 7, 8 występują duże skoki w wartości obrotu. Ponownie stworzymy formułę rozdzielającą bonusy na poszczególne miesiące, co pozwoli nam dokładniej wygładzić dane.

Expression

```
1 if($Month (Number)$==1 || $Month (Number)$==2, -300, if($Month (Number)$==6 || $Month (Number)$==7 || $Month (Number)$==8 ,300,0))
```


Rysunek 14: Formuła dotycząca bonusu miesięcznego.

Dzięki opracowanej formule rozdzielającej bonusy na poszczególne miesiące, możemy teraz wygładzić nasze dane za pomocą kolejnej formuły.

Expression

```
1 $wygładzenie tygodniowe$ -$bonus miesięczny$
```

Rysunek 15: Formuła - wygładzenie miesięczne



Rysunek 16: Wygladzenie miesieczne - wykres


Na powyższym wykresie widać, że udało nam się wygładzić obroty spowodowane sezonowością. Kolejnym krokiem w naszej analizie będzie zajęcie się wygładzeniem skoków wynikających z wahań liczby konkurencji.

Użyjemy następującej formuły:

Expression
1 $\text{\$wygladzenie miesieczne\$} + (350 * \text{\$liczba konkurencji\$})$

Rysunek 17: Formuła - dane wygładzone

A tak przedstawiają się już całkowicie wygładzone dane:



Rysunek 18: Dane wygładzone - wykres

Po całkowitym wygładzeniu danych możemy przystąpić do stworzenia modelu regresji liniowej, wykorzystując node **Linear Regression Learner**.

Opracowany w ten sposób model posłuży jako podstawa do budowy naszego modelu finalnego, umożliwiając bardziej precyzyjne prognozowanie i analizę.

Wynik node'a Linear Regression Learner:

Statistics on Linear Regression

Variable	Coeff.	Std. Err.	t-value	P> t
t	14,9615	0,0008	18 356,0965	0.0
Intercept	1 623,4362	4,1255	393,5153	0.0

R-Squared: 1

Adjusted R-Squared: 1

Rysunek 19: Wynik node'a Linear Regression Learner

Na podstawie otrzymanego wyniku stworzymy model finalny, wykorzystując następującą formułę:

Expression
1 14.92*\$t\$+1620


Rysunek 20: Model finalny

Na podstawie opracowanego modelu finalnego oraz formuł modelujących bonusy stworzymy końcowy model, który będzie precyzyjnie odwzorowywał wartości obrotu.

Expression
1 \$model finalny\$ +(350*\$liczba konkurencji\$)+\$bonus miesięczny\$+\$bonus dzień\$

Rysunek 21: Model z bonusami

Teraz przejdziemy do sprawdzenia, jak nasz końcowy model faktycznie działa w praktyce. Przetestujemy go na zbiorze testowym, aby zweryfikować jego skuteczność. Następnie porównamy uzyskane predykcje z rzeczywistymi wartościami, prezentując wyniki na wykresie. Dzięki temu będziemy mogli ocenić, jak dobrze model odwzorowuje wartości obrotu.



Rysunek 22: Model z bonusami

Na powyższym wykresie widać, że nasz końcowy model bardzo dobrze odwzorowuje wartości obrotu. Linie przedstawiające rzeczywiste dane i predykcje są niemal identyczne, co potwierdza wysoką dokładność modelu. Jednak, aby dodatkowo potwierdzić jego skuteczność, obliczymy błąd względny. Pozwoli nam to dokładnie ocenić, jak bardzo model różni się od rzeczywistych danych, co da nam jeszcze większą pewność co do jego niezawodności.


Do wyliczenia błędu względnego zastosujemy następującą formułę:

Expression

```
1 abs($obrót$-$model z bonusami$)/$obrót$
```

Rysunek 23: Formuła do błędu względnego

Obliczymy błąd względny za pomocą node'ów:



Rysunek 24: Wyliczenie błędu względnego

Poniższy rysunek przedstawia kluczowe statystyki opisujące błąd względny.



Rysunek 25: Podstawowe statystyki błędu względnego

Zakres wartości (Min i Max):

- **Min:** Najniższa wartość błędu względnego wynosi **0,0031**, co wskazuje, że w najlepszych przypadkach prognozy modelu niemal idealnie odwzorowują rzeczywistość.
- **Max:** Najwyższa wartość błędu względnego wynosi **0,0082** (0,82%), co oznacza, że nawet w najgorszych przypadkach błąd modelu pozostaje bardzo niski i mieści się w akceptowalnych granicach.

Średnia (Mean):

- Średnia wartość błędu względnego to **0,0056** (0,56%), co świadczy o wysokiej precyzji modelu i dobrym dopasowaniu do rzeczywistych danych.

Odchylenie standardowe (Std. Dev.):

- Wartość odchylenia standardowego wynosi **0,0011**, co oznacza, że rozrzut błędów jest bardzo mały, a prognozy modelu są stabilne w różnych przypadkach.


Histogram:

- Histogram przedstawia rozkład błędów względnych, który jest skoncentrowany wokół średniej wartości **0,0056**.
- Większość błędów znajduje się w wąskim zakresie od **0,0031** do **0,0082**, co potwierdza, że model działa spójnie i nie popełnia znaczących błędów.
- Rozkład błędów jest symetryczny i nie wykazuje znaczących odstępstw, co podkreśla stabilność i równomierność działania modelu.

Teraz zbudujemy 3 różne modele oparte o narzędzia uczenia maszynowego.

Jako pierwszy zbudujemy model oparty na algorytmie drzewa regresyjnego (**Simple Regression Tree**). Algorytm ten tworzy drzewo decyzyjne, które iteracyjnie dzieli dane na węzły, minimalizując błąd prognoz w każdym kroku.

Zaczynamy od użycia node'a **Simple Regression Tree Learner** i podłączenia do niego zbioru uczącego.




Rysunek 26: Ustawienia node'a Simple Regression Tree Learner

Następnie wykorzystamy node **Simple Regression Tree Predictor**, aby wygenerować prognozy na podstawie wyuczonego modelu. Kolejnym krokiem będzie obliczenie błędu względnego, wykonane analogicznie do procesu przeprowadzonego wcześniej dla własnego modelu. W tym celu zastosujemy node **Math Formula**, który użyje tej samej formuły do wyliczenia błędu względnego.

Pozostałe dwa modele oparte na **Gradient Boosted Trees** oraz **Random Forest** – zostały stworzone w sposób analogiczny, z wykorzystaniem odpowiednich node'ów uczenia i predykcji:

- **Gradient Boosted Trees Learner (Regression) i Predictor (Regression)** dla modelu Gradient Boosted Trees,
- **Random Forest Learner (Regression) i Predictor (Regression)** dla modelu Random Forest.

Schemat działania przy tworzeniu wszystkich modeli został przedstawiony na poniższym rysunku:




Rysunek 27: Schemat dla wszystkich 3 modeli


Poniżej przedstawiono podstawowe statystyki błędu względnego dla poszczególnych modeli: **Simple Regression Tree**, **Gradient Boosted Trees** oraz **Random Forest**:



Rysunek 28: Podstawowe statystyki błędu względnego (Simple Regression Tree)



Rysunek 29: Podstawowe statystyki błędu względnego (Gradient Boosted Trees)



Rysunek 30: Podstawowe statystyki błędu względnego (Random Forest)

Aby ułatwić porównanie wyników poszczególnych modeli, przedstawiamy je w formie tabeli:

Model	Min	Mean	Max	Std.Dev.
Własny model	0,0031	0,0056	0,0082	0,0011
Simple Regression Tree	0,000083	0,0232	0,0432	0,0126
Gradient Boosted Trees	0,001	0,0244	0,0432	0,0124
Random Forest	0,0425	0,0625	0,0892	0,0099


Powyższa tabela przedstawia podstawowe statystyki błędu względnego dla czterech porównywanych modeli: własnego modelu liniowego oraz trzech modeli opartych o narzędzia uczenia maszynowego. Porównanie obejmuje minimalne, średnie i maksymalne wartości błędu oraz odchylenie standardowe.

Wnioski:

- **Własny model liniowy** osiągnął najniższą średnią wartość błędu względnego (**0,0056**) oraz najmniejsze odchylenie standardowe (**0,0011**), co pokazuje, że jest bardzo stabilny i precyzyjny w prognozowaniu.
- Modele **Simple Regression Tree** i **Gradient Boosted Trees** uzyskały zbliżone wyniki, ale ich średnia oraz maksymalna wartość błędu są wyższe w porównaniu do własnego modelu liniowego, co oznacza, że są mniej dokładne.
- Model **Random Forest**, choć wykazuje najniższą wartość odchylenia standardowego spośród modeli opartych o narzędzia uczenia maszynowego (**0,0099**), cechuje się najwyższą średnią (**0,0625**) i maksymalną (**0,0892**) wartością błędu względnego.

Podsumowując, własny model okazał się najbardziej precyzyjny w prognozowaniu, jednak modele uczenia maszynowego, mimo nieco większych błędów, również charakteryzują się na tyle małymi wartościami błędu względnego, że mogłyby być z powodzeniem stosowane w predykcjach dotyczących obrotu. Ich wyniki wskazują na dużą użyteczność.

Tak prezentuje się pełny schemat projektu w KNIME, który obejmuje wszystkie etapy.



Rysunek 31: Wygląd całego schematu w KNIME